

# 北京市十一学校

## 机器学习课程概览

2023年7月

郑子杰 北京市十一学校

韩思瑶 北京市十一学校

张炜其 北京市十一学校

汪星明 北京市十一学校

龚超 清华大学



# 北京市十一学校 机器学习 课程设计与实施

## 目录

### 中学机器学习十五讲 课程框架

### 面向对象与课程目标

### 课程参考书目

第一讲 人工智能的定义

第二讲 人工智能发展简史

第三讲 连接主义与机器学习

第四讲 面向对象的编程与机器学习标准库

第五讲 机器学习训练模型的数学范式

第六讲 监督学习与逻辑斯蒂回归

第七讲 求解机器学习问题——优化理论

第八讲 神经网络与反向传播算法

第九讲 距离与 K 近邻算法

第十讲 支持向量机

第十一讲 贝叶斯理论

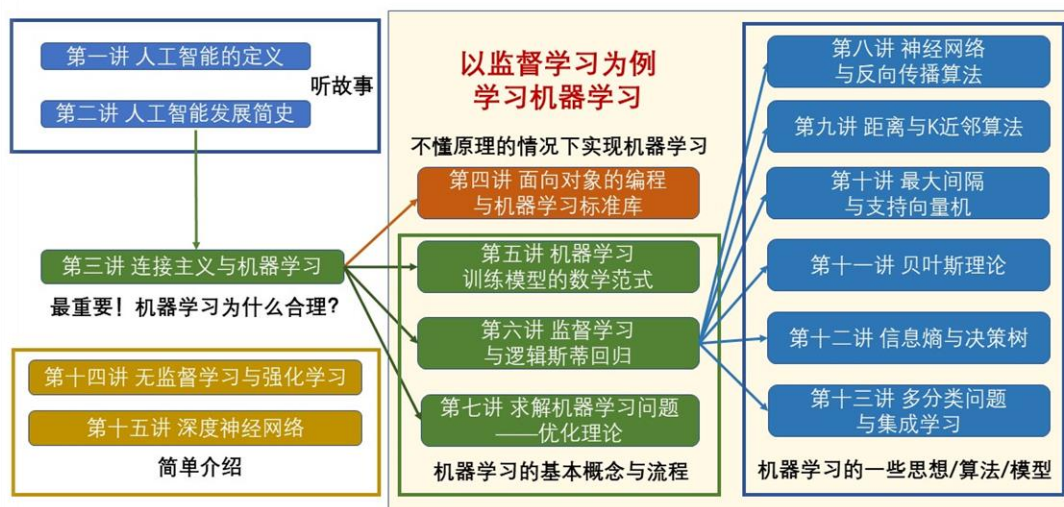
第十二讲 信息熵与决策树

第十三讲 多分类问题与集成学习

第十四讲 无监督学习与强化学习

第十五讲 深度神经网络

## 中学机器学习十五讲 课程框架



## 面向对象与课程目标

• 面向对象（可调整）：具有高一数学基础+python编程基础的人

- ① 学过函数（一次函数、二次函数、反比例函数、幂函数、指数函数、对数函数）
- ② 知道平均变化率的概念或导数的概念
- ③ 了解概率的基本概念（至少知道概率的定义、平均值、方差等统计量）
- ④ 掌握平面向量的基本定义和运算法则
- ⑤ 会Python的基本语法，知道如何调用Python OS\math\numpy等库

• 通过学习这门课，你能掌握：

- ① 机器学习的基本概念和流程
- ② 一些典型的基础思想/算法/模型
- ③ 基于Python的机器学习库的常见使用方式
- ④ 数据意识——用数据建立模型，并解决问题的基本意识和方法（与传统中学教学有所区别）



## 本课程参考文献（面向学生的措辞）

0. 如果你只了解人工智能：《人工智能（高中版）》
  - 姚期智版、汤晓鸥版、李国良版均可
1. 如果你只想看专业的段子：尼克《人工智能简史》
2. 如果你想应用，玩花活，快速形成展示项目，不用搞清楚原理：sklearn中文文档 + pytorch
  - <1><https://www.scikitlearn.com.cn/>
  - <2><https://tensorflow.google.cn/>
  - <3><https://pytorch.org/docs/stable/>算法都是现成的，直接调库就可以了。
3. 如果你想简单了解机器学习算法：李航《统计学习方法》或周志华《机器学习》
4. 如果你想入门机器学习算法：Bishop《Pattern Recognition & Machine Learning》

5. 如果你真的想学习人工智能（机器学习）算法，并可以讲给别人听：

- ① 你可以把高中数学讲给别人听
- ② 你可以把高等数学 & 线性代数 & 概率统计讲给别人听
- ③ 你可以把随机过程 & 信号与系统 & 信息论讲给别人听
- ④ 你可以把数值优化理论（凸优化、遗传算法等）讲给别人听
- ⑤ 你可以把Theodoridis的《模式识别》Pattern Recognition讲给别人听

6. 如果你真的想从事人工智能相关领域的研究，选至少一个应用方向读论文、写论文；选至少一个理论方向进行深入研究。

- ① 计算机视觉 Computer Vision (CV)
- ② 自然语言处理 Natural Language Processing (NLP)
- ③ ...




## 第一讲 人工智能的定义

学习目标：了解人工智能的应用，了解人工智能这个词的诞生与图灵测试

- 1956年，达特茅斯会议
- In Dartmouth College in 1956
- John McCarthy（发起人）、Marvin Minsky、Oliver Selfridge、Allen Newell、Claude Shannon、Hebert Simon
- 讨论每个人理解的人工智能，虽在理解上分歧，但也产生了一个新的名词Artificial Intelligence



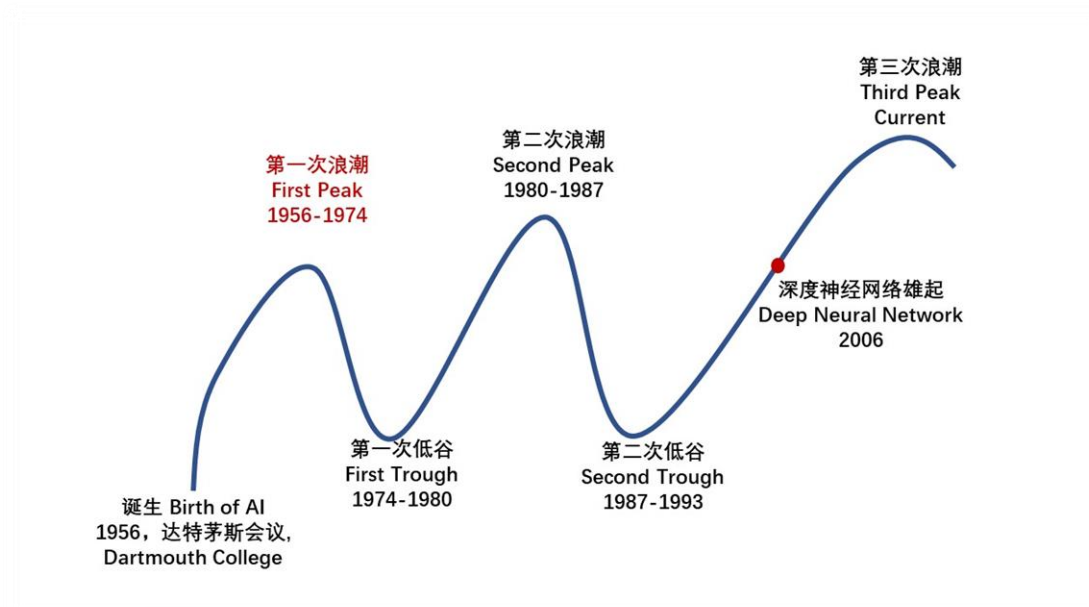
- 来自英国的天才——Alan Turing 艾伦·图灵
- 1950年发表的“计算原理与智能”（Computing Machinery and Intelligence）论文中提出了关于AI如何定义——**图灵测试**。
- 有一个屋子，如果在屋外的一个人类，在屋内有一台计算机或者一个人。屋外的人在提出一些书面问题之后，无法分辨这些书面回答究竟是来自于人还是一台计算机，则认为计算机通过了图灵测试。



（以上 PPT 均来自于本章实际授课课件）

## 第二讲 人工智能发展简史

学习目标：了解人工智能的关键结束诞生的历史节点，区分业界的人工智能与学术圈的人工智能发展的节奏差异



### 2006标志性事件

G. E. Hinton团队改进了神经网络的训练算法，用深度神经网络实现了图像压缩与重构

深度神经网络就是增加网络层数，其核心贡献是改进了训练算法验证了增加层数的有效性，与**思维深度**之类的含义无关，请不要过度解读！




Figure 1: A snapshot of two root-to-leaf branches of ImageNet: the top row is from the mammal subtree; the bottom row is from the vehicle subtree. For each column, 9 randomly sampled images are presented.

### 数据集的扩大

例：图像处理 Image Processing  
2009, ImageNet, Feifei Li  
14,197,122 图片  
21841 种类

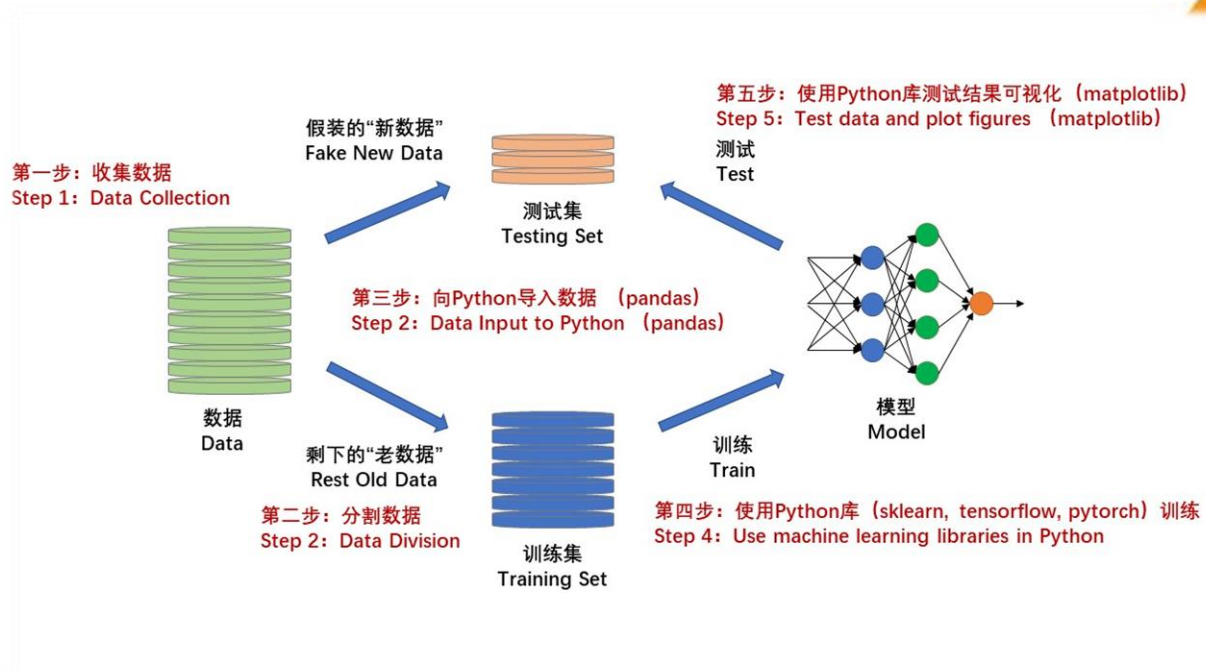
(以上 PPT 均来自于本章实际授课课件)






## 第四讲 面向对象的编程与机器学习标准库

学习目标：老师配置环境，学生能够理解并实践使用 Python  
快速实现流程，同时明确实践只是操作，原理需要学习



- 机器学习的入门标准库：scikit-learn(sklearn)
- 英文版文档：<https://scikit-learn.org/>
- 中文版文档：<https://www.scikitlearn.com.cn/>
- 中文文档只是原理部分是中文的，函数文档部分还是英文的
- sklearn标准三行：
  - ① 定义一个叫做clf的模型：`clf = neighbors.KNeighborsClassifier(15)` #选择sklearn里面一个自带的KNN模型
  - ② 用训练数据训练clf模型：`clf.fit(X_train,y_train)` #使用训练数据训练
  - ③ 用测试数据进行预测，返回准确率等指标：`accuracy = clf.score(X_test,y_test)` #使用测试数据测试准确率
- 使用matplotlib库进行科学画图 <https://matplotlib.org/>
- 导入matplotlib的一般绘图模块pyplot：`import matplotlib.pyplot as plt`
- 导入matplotlib染色模块：`from matplotlib.colors import ListedColormap`
- 使用matplotlib进行画图：
 

```
plt.figure(2) #第几张图
plt.pcolormesh(xx, yy, y_predict, cmap=cmap_light)
plt.scatter(X[:, 0], X[:, 1], c=y, cmap=cmap_bold, edgecolor='k', s=20)
plt.xlim(xx.min(), xx.max())
plt.ylim(yy.min(), yy.max())
plt.xlabel("Sepal.Length")
plt.ylabel("Sepal.Width")
plt.title("KNN, Iris")
```




(以上 PPT 均来自于本章实际授课课件)



## 第五讲 机器学习训练模型的数学范式

学习目标：了解机器学习进行训练的关键概念，明确决策函数、损失函数、优化目标、优化方法

### 机器学习训练模型的数学范式 Mathematical Paradigm



① 选择一个模型的基本形式

Find a basic form of model

$$f_{\theta}(x) = \theta_0 + \theta_1 x \quad \text{决策函数 Decision Function}$$

② 定义拟合好坏的判定函数（距离远近）

Define the judgment function of good or bad fitting (the distance between training data and model)

$$L(f_{\theta}(x), y) = (f_{\theta}(x) - y)^2 \quad \text{损失函数 Loss Function}$$


③ 参数确定：最小化损失和

Objective: minimize the sum loss of the data

$$\min_{\theta} \sum_{i=1}^N L(f_{\theta}(x_i), y_i) \rightarrow \{\theta_0, \theta_1, \dots\}$$

④ 求解：随机优化 凸优化（本节课不讲）


- 我们从美国疾病预防控制中心的官网下载了2020年三月下旬CDC报告的全美每日感染人数的报告。
- 任务：根据3月份数据（训练集）**建立模型**，**预测**美国4月（测试集）的新冠感染人数变化。



$$f_{\theta}(x) = \theta_0 + \theta_1 x$$

**欠拟合 Under-fitting:**


对训练数据拟合的不够，模型不够精确，自然对测试数据预测也会有一定偏离



$$f_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2$$

**较好的拟合 Proper-fitting:**

- ① 对训练数据拟合准确
- ② 能预测测试数据，有**泛化**能力



$$f_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots$$

**过拟合 Over-fitting:**

对训练数据拟合的过份了，导致看不出趋势，无法预测测试数据（失去**泛化**能力）

（以上 PPT 均来自于本章实际授课课件）

## 第六讲 监督学习与逻辑斯蒂回归

学习目标：了解监督学习的基本概念，了解逻辑斯蒂回归的原理与推导过程，使用 Sklearn 实现逻辑斯蒂回归

### 逻辑斯蒂回归——体温检测

回顾100年前的分类问题建模...


把样本分成**两类**：生病的人 ( $y_i=1$ )，不生病人 ( $y_i=0$ )

$f_{\theta}(x_i)$ ：模型预测的得病概率

① 不得病的人 ( $y_i = 0$ )，决策函数预测不得病的概率**越大越好**，暨输出为0的概率越大越好：

② 得病的人 ( $y_i = 1$ )，决策函数预测得病的概率**越大越好**：

$$\begin{array}{lcl}
 \text{当 } y_i = 0 \text{ 时, } \max_{\theta} 1 - f_{\theta}(x_i) & \xrightarrow{\text{Step1 任何数的1次方都等于它本身}} & \max_{\theta} (1 - f_{\theta}(x_i))^{1-y_i} \\
 & \xrightarrow{\text{Step2 非零数的零次方等于1}} & \max_{\theta} (1 - f_{\theta}(x_i))^{1-y_i} \underbrace{(f_{\theta}(x_i))^{y_i}}_1 \\
 & & \text{格式统一了!} \\
 \text{当 } y_i = 1 \text{ 时, } \max_{\theta} f_{\theta}(x_i) & \xrightarrow{\text{Step1 任何数的1次方都等于它本身}} & \max_{\theta} (f_{\theta}(x_i))^{y_i} \\
 & \xrightarrow{\text{Step2 非零数的零次方等于1}} & \max_{\theta} (1 - f_{\theta}(x_i))^{1-y_i} \underbrace{(f_{\theta}(x_i))^{y_i}}_1
 \end{array}$$



### 关于分类问题的讨论

问题一：衡量模型进行分类好坏的指标是什么？

问题二：每个样本特征 (Feature)，也就是模型中的  $x$ ，必须是一个数么？

问题三：样本的种类，或者说**标签 (Label)**，有**超过两种**，怎么办？



② 处理方法2：强行看成二分类，建立**多个**分类器，然后**投票**


• 建立3个二分类器，**强行默认**样本只含有两类

(A) 狗vs猫  $f$

(B) 猫vs鼠  $g$

(C) 鼠vs狗  $h$

最后再组合判定输出



问题四：样本没有**标签 (Label)**，就不能建立模型进行分类了么？

(以上 PPT 均来自于本章实际授课课件)




## 第七讲 求解机器学习问题——优化理论

学习目标：基于最简单的例子，了解优化算法的两种主要思路，随机优化方法与凸优化方法


### 随机优化 Stochastic Optimization

$$\min_x f(x)$$

$$f(x) = \sqrt{|x^2 - 10x + 4|} + \sqrt{|x^4 - 3x + 1|}$$



### 凸优化 Convex Optimization



- 回顾我们数学课上学的单调性
- 在有导数工具之后，我们可以求一阶导数的方法代替差分

$$\frac{f(x_k + \Delta_2) - f(x_k - \Delta_1)}{x_k + \Delta_2 - (x_k - \Delta_1)} > 0$$

$$\frac{df(x_k)}{dx} = \lim_{\Delta \rightarrow 0} \frac{f(x_k + \Delta) - f(x_k)}{\Delta} = \lim_{\Delta \rightarrow 0} \frac{f(x_k) - f(x_k - \Delta)}{\Delta} > 0$$

- 注意：实际问题中为了数值处理，有时候可以用差分代替导数。这两者在优化思想上没有本质区别，都是利用单调性
- 所以一个找下一步让函数值最小的点的一般方法

$$x_{k+1} = x_k - \alpha \frac{df(x_k)}{dx} \quad \text{其中 } \alpha > 0$$

梯度下降法 (Gradient Descent Method)


(以上 PPT 均来自于本章实际授课课件)

## 第八讲 神经网络与反向传播算法

学习目标：了解神经网络的基本结构，明确神经网络出现逻辑为：数据的复杂导致模型不得不复杂

### 神经网络的结构 Structure of Neural Network

①决策函数 (Decision Function) :  $y^{(1)} = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x^{(1)} + \theta_2 x^{(2)})}}$   $y^{(2)} = \frac{1}{1 + e^{-(\phi_0 + \phi_1 y^{(1)} + \phi_2 x^{(2)})}}$   $y = \frac{1}{1 + e^{-(\omega_0 + \omega_1 y^{(1)} + \omega_2 y^{(2)})}}$




简化后的iris数据集：包含100个数据样本，分为2类，每类50个数据，每个数据包含2个属性。可通过花萼长度 (Sepal.Length)，花萼宽度 (Sepal.Width) 2个属性预测鸢尾花卉属于 (Sentosa 0, Versicolor 1) 两个种类中的哪一类。

如果使用sklearn库，可以直接调用现成的分类器模型：


含有一个隐含层（一共两层）、隐含层神经元个为5的神经网络模型

sklearn自带的神经网络模型对testing set实现分类

```
clf = MLPClassifier(solver='lbfgs', alpha=1e-5, hidden_layer_sizes=(5), random_state=1)
```



这个分线是怎么画出来的




(以上 PPT 均来自于本章实际授课课件)




## 第九讲 距离与 K 近邻算法

学习目标：了解距离可以测量相似性，了解 K 近邻算法的设计逻辑和基本实现方法

简化后的Iris数据集：包含100个数据样本，分为2类，每类50个数据，每个数据包含2个属性。  
可通过花萼长度 (Sepal.Length)，花萼宽度 (Sepal.Width) 2个属性预测鸢尾花卉属于 (Sentosa 0, Versicolor 1) 两个种类中的哪一类。



红点：Sentosa, 0 蓝点：Versicolor, 1



K越大，分界线倾向于越平滑  
但是K太大会增加不必要的计算量

### 距离的度量 Distance

- 问题二：如何定义“近”




直观上可以用“距离”来度量

- 欧几里得距离：  $d_{i,j} = \left( \sum_{m=1}^M (x_i^{(m)} - x_j^{(m)})^2 \right)^{\frac{1}{2}}$

- 曼哈顿距离 Manhattan Distance:

起源于城市之间的距离，因为城市之间的路多是正南正北或者正东正西走向的，所以曼哈顿距离相当于各维度上分别求距离然后再求和

$$d_{i,j} = \sum_{m=1}^M |x_i^{(m)} - x_j^{(m)}|$$



(以上 PPT 均来自于本章实际授课课件)



## 第十讲 支持向量机

学习目标：了解支持向量机的核心思想——最大间隔，明确支持向量机的优化目标，简单了解如何求解（不要求）

- 支持向量机的大致想法：
- 由画“线”变成画“沟”，也就是用两条平行的直线将两类数据分隔开
- 找到两条平行直线（超平面），让这两条平行直线之间的距离最大，也就是沟最宽。

按照机器学习的数学范式：

- ① 决策函数 Decision Function：两条直线
- ② 损失函数 Loss Function：两条直线之间的间隔
- ③ 优化目标 Objective：间隔最大



用以确定直线的点叫作支持向量 (Supporting Vector)

$$(x^{(1)}, x^{(2)})$$

- ① 在平面解析几何中，两条平行直线的方程？

两条平行直线的方程为：

$$Px^{(1)} + Qx^{(2)} + M_1 = 0$$

$$Px^{(1)} + Qx^{(2)} + M_2 = 0$$


- ② 经过简单的代数变形，两条平行直线的解析式可以写成（只是解析式的形式发生改变，直线还是那两条直线）

$$Ax^{(1)} + Bx^{(2)} + C = 1$$

$$Ax^{(1)} + Bx^{(2)} + C = -1$$

$$\begin{aligned} Px^{(1)} + Qx^{(2)} + M_1 = 0 & \xrightarrow{\text{两边同乘}} \frac{2P}{M_1 - M_2}x^{(1)} + \frac{2Q}{M_1 - M_2}x^{(2)} + \frac{2M_1}{M_1 - M_2} = 0 \\ Px^{(1)} + Qx^{(2)} + M_2 = 0 & \xrightarrow{\frac{2}{M_1 - M_2}} \frac{2P}{M_1 - M_2}x^{(1)} + \frac{2Q}{M_1 - M_2}x^{(2)} + \frac{2M_2}{M_1 - M_2} = 0 \end{aligned}$$

$$\begin{aligned} A &= \frac{2P}{M_1 - M_2} \\ B &= \frac{2Q}{M_1 - M_2} \\ C &= \frac{M_1 + M_2}{M_1 - M_2} \end{aligned}$$



- ③ 红色的点：label  $y = 1$ ，蓝色的点：label  $y = -1$

红色的点在上面直线的上方：  $x^{(2)} \geq \frac{1 - C - Ax^{(1)}}{B} \rightarrow Ax^{(1)} + Bx^{(2)} + C \geq 1$

蓝色的点在下面直线的上方：  $x^{(2)} \leq \frac{-1 - C - Ax^{(1)}}{B} \rightarrow Ax^{(1)} + Bx^{(2)} + C \leq -1$

（以上 PPT 均来自于本章实际授课课件）

## 第十一讲 贝叶斯理论

学习目标：学会用概率的眼光看世界，了解朴素贝叶斯算法的基本原理

- 条件概率的常见公式：
  - A事件已经发生的条件下，B发生的概率
 
$$P(B|A) = \frac{P(AB)}{P(A)}$$
- 贝叶斯公式（逆概公式）：
 
$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(A|B)P(B)}{P(A)}$$
- 全概率公式（全概公式）：
 
$$P(A) = P(AB) + P(A\bar{B})$$

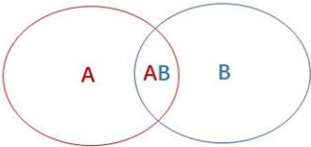
$$= P(A|B)P(B) + P(A|\bar{B})P(\bar{B})$$
- 贝叶斯公式的应用：
 
$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(A|B)P(B)}{P(A)}$$

$A$ : 核酸检测为阳性  
 $B$ : 患有新冠  
 新冠患者中核酸检测为阳性的比例  
 求  $P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(A|B)P(B)}{P(A)}$   
 $P(A)$  总人群中核酸检测为阳性的比例 (?)

全概率公式

$$P(A) = P(A|B)P(B) + P(A|\bar{B})P(\bar{B})$$

非患者中核酸阳性的比例  
 $1 - P(\bar{A}|\bar{B})$   
 非患者中核酸阴性的比例  
 \*以上数据均非真实数据



### 朴素贝叶斯方法 Naïve Bayes Model

- 在体温为 $x$ 时，计算生病（1）和不生病（0）的概率，哪个大，则归在哪一类。

$$y = f_{\theta}(x) = \arg \max_{c \in \{0,1\}} P(c|x) = \begin{cases} 1, & P(1|x) \geq P(0|x) \\ 0, & P(1|x) < P(0|x) \end{cases}$$

模型的关键：根据训练集数据计算  $P(c|x)$  的方法

由贝叶斯公式：类别 $c$ （例如 $c=1$ 生病）中，体温为 $x$ 的概率

$$P(c|x) = \frac{P(cx)}{P(x)} = \frac{P(x|c)P(c)}{P(x)}$$

类别 $c$ （例如 $c=1$ 生病）出现的概率，  
 可以直接用 $c$ 类样本在总样本中的占比估计： $P(c) = \frac{D_c}{D}$   
 不依赖于类别，代表全体人群中体温为 $x$ 的概率，所以可以去掉

决策函数相应的变为：

$$f_{\theta}(x) = \arg \max_{c \in \{0,1\}} P(x|c)P(c) = \arg \max_{c \in \{0,1\}} P(x|c) \frac{D_c}{D}$$

（以上 PPT 均来自于本章实际授课课件）

## 第十二讲 信息熵与决策树

学习目标：了解信息熵作为损失函数的精髓，以决策树作为载体体会信息熵

- 假定当前样本集合  $D$  中（共  $D = |D|$  个样本）第  $k$  类样本的个数为  $D_k$ ，相应的占比为： $p_k = \frac{D_k}{D}$

- 信息熵： $E(D) = -\sum_{k=1}^K p_k \log_2 p_k$

例  $\{0, 1, 0, 1, 0, 0, 0, 0\}$

$$E(D) = -\sum_{k=1}^K p_k \log_2 p_k = \underbrace{\left(-\frac{2}{8} \log_2 \frac{2}{8}\right)}_{2 \text{ 个 } 1} + \underbrace{\left(-\frac{6}{8} \log_2 \frac{6}{8}\right)}_{6 \text{ 个 } 0} \approx 0.8113$$

例（最纯）  $\{0, 0, 0, 0, 0, 0, 0, 0\}$   $E(D) = -\sum_{k=1}^K p_k \log_2 p_k = -\frac{8}{8} \log_2 \frac{8}{8} = 0$

例（最不纯，样本均分）  $\{0, 0, 1, 1, 1, 0, 0\}$   $E(D) = -\sum_{k=1}^K p_k \log_2 p_k = -\frac{4}{8} \log_2 \frac{4}{8} + \left(-\frac{4}{8} \log_2 \frac{4}{8}\right) = 1$

最纯，只含一类：熵最小=0；最不纯，各类均分，熵最大

- 形成决策树的一个思路：
- 一个feature一个feature的进行考虑
- 每一次选择一个feature的分界线，使得分出来的若干个叶子（集合）的信息增益最大（类似贪心算法）



$$(x^{(k)}, x_{th}^{(k)}) = \arg \max_{x^{(k)}, x_{th}^{(k)}} \text{Gain}(D, \{D_j\}) = \arg \max_{x^{(k)}, x_{th}^{(k)}} E(D) - \sum_{j=1}^J \frac{|D_j|}{|D|} E(D_j)$$

选出来的  
feature

选出来的feature  
的分界线

例，第一步发现选择  $x^{(1)}$ ，且

$x^{(1)} = 3$  时，信息增益最大



（以上 PPT 均来自于本章实际授课课件）







## 第十四讲 无监督学习与强化学习

学习目标：了解无监督学习和强化学习的基本概念（不作为重点）

- K-Means 算法
- 基本思想分为两步：
  - ① 自己看完数据后，通过直观**拍脑袋决定**分为k类；
  - ② 随机选择k个中心，作为起始的k类的中心
    - <i> 样本与哪个中心近就归在哪一类；
    - <ii> 把每一类的样本的**几何位置求个平均**，作为这一类的**新中心**
- 重复②直到停止。
- K均值算法的收敛性：
  - 可以**很轻松的证明**，随着K均值算法的迭代，总距离和一定是越来越小
  - 最后一定是聚类聚的越来越好（更靠近的点被分在了一个类里）



满足以下两点：A. 目标函数有下界；B. 每一步一定是严格递减

- 马尔可夫决策 Markov Decision Process：转移概率不仅仅是客观因素还跟**人为干预/行动 (Action)** 有关

$$R_i^\pi = \sum_a \pi(A=a | \xi=i) \cdot R_i^a$$


$$R(t) = \sum_i \omega_i(t) R_i^\pi(t)$$

可以根据马尔可夫链的计算方法算出来  
态概率  $\omega_i(t)$ ， $R(t)$  为当前时刻的期望收益

$$G_t = \sum_{u=t}^{\infty} \gamma^{u-t} R(u) = R(t) + \gamma R(t+1) + \gamma^2 R(t+2) + \dots$$

把后续收益也考虑进去，考虑贴现因子  
(discount factor)  $0 \leq \gamma < 1$

目标：合理规划**决策概率**使得期望收益最大  $\max_{\pi(A|\xi)} G_t$  **强化学习 Reinforcement Learning**




(以上 PPT 均来自于本章实际授课课件)

## 第十五讲 深度神经网络

学习目标：了解深度神经网络的核心改进，了解卷积神经网络的基本结构和设计思路

### 深度神经网络 Deep Neural Network

- 其解决的问题是一个无监督学习问题（图像压缩问题）：
- 一个2000 feature 的图片用30个label表示，然后再用30个label将图片重新恢复
- 使用神经网络的结构进行压缩，目标是让重构错误率最小：



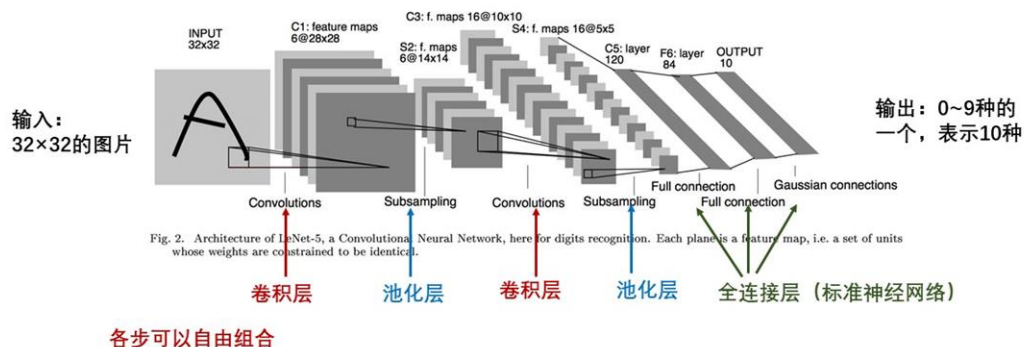
- 每一层的训练：
- 受限玻尔兹曼机 Restricted Boltzmann Machine, RBM
- 激活函数 Activation Function，选用Softmax函数

$$Act(x) = \frac{e^{-\theta^T x}}{\sum_{k=1}^K e^{-\theta^T x_k}}$$

- 生成方式采用模拟玻尔兹曼分布的生成方式：
- \*吉布斯抽样 Gibbs Sampling
- 每一层的训练完再把各层拼起来

### 卷积神经网络 Convolutional Neural Network

- 例：LeNet-5, LeCun Yann et al., 1998



（以上 PPT 均来自于本章实际授课课件）



北京十一学校  
BEIJING NATIONAL DAY SCHOOL

